

Laboratorium 7 – algorytm k-środków

Streszczenie

Dla zbioru danych $X_{n \times m}$ algorytm k-środków realizuje się za pomocą dwóch macierzy:

1. $P_{n \times 1}$ – macierzy przynależności wektorów danych, gdzie $P(i) = w \in [1, 2, \dots, k]$ określa do której grupy C_k należy dany wiersz danych,
2. $C_{k \times m}$ – macierzy środków, każdy z wierszy zawiera średnie wartości dla każdej z kolumn danych, które należą do tej grupy.

Algorytm inicjujemy startowymi środkami. Można to zrobić na 2 sposoby:

- Wybierając losowe wiersze z naszych danych jako środki (`numpy.random.choice`)
- Przypisując każdy z punktów do losowej klasy, a następnie wyliczyć środki.

Do nauczenia naszego klasyfikatora wykonujemy poniższe kroki algorytmu. Wykonujemy je do czasu aż wyniki się ustabilizują, czyli macierze P i C przestaną się zmieniać lub przez kilka ostatnich iteracji wyniki są podobne (na przykład 1 wektor danych przeskakuje ciągle między dwoma klasami, a pozostałe są bez zmiany).

1. Dla każdego wiersza danych wyliczamy jego odległości do wszystkich środków,
2. Aktualizujemy macierz P tak, aby wskazywała na ten środek, który jest dla niego najbliższy,
3. Aktualizujemy współrzędne środków w macierzy C na podstawie, aktualnej macierzy przynależności, czyli wyliczenie średniej wartości parametrów dla każdej z grup.

Nauczony klasyfikator będziemy mogli również wykorzystywać do zadania klasyfikacji. W tym celu będziemy podawać dane i sprawdzać, do którego z posiadanych przez grup możemy je zaliczyć.

1 Cel

Zapoznanie się z algorytmem k-środków oraz jego implementacja.

2 Zadania

1. Napisać funkcje:

- $d=\text{distp}(\mathbf{X}, \mathbf{C})$, która wyliczy odległość euklidesową między dwoma zbiorami punktów $\mathbf{X}$ i $\mathbf{C}$:

$$d_e(\mathbf{x}_i, \mathbf{c}_k) = \sqrt{(\mathbf{x}_i - \mathbf{c}_k)(\mathbf{x}_i - \mathbf{c}_k)^T}.$$

- $d=\text{distm}(\mathbf{X}, \mathbf{C}, \mathbf{V})$, która wyliczy odległość Mahalanobis'a między dwoma zbiorami punktów $\mathbf{X}$ i $\mathbf{C}$; $\mathbf{V}$ jest macierzą kowariancji zbioru $\mathbf{X}$ (alternatywnie można ją obliczać wewnątrz funkcji):

$$d_m(\mathbf{x}_i, \mathbf{c}_k) = \sqrt{(\mathbf{x}_i - \mathbf{c}_k) \mathbf{V}^{-1} (\mathbf{x}_i - \mathbf{c}_k)^T}.$$

- $[\mathbf{C}, \mathbf{CX}] = \text{ksrodki}(\mathbf{X}, k)$, która dla zadanej macierzy wzorców $\mathbf{X}$ oraz liczby grup k , wyznaczy centra $\mathbf{C}$ i sąsiedztwa $\mathbf{CX}$.

2. Zilustrować graficznie wyniki działania algorytmu. Wybrać kilka różnych parametrów ze zbioru **autos** (2, 3, 4, 5 itd.) i zaprezentować jak one są grupowane. Dla więcej niż 3 parametrów do prezentacji proszę wykorzystać PCA.

3. Obliczyć jakość grupowania:

$$F(C) = \frac{\sum_{k=1}^{K-1} \sum_{l=k+1}^K d(c_k, c_l)}{\sum_{k=1}^K \sum_{x \in C_k} d^2(x, c_k)} \quad (1)$$