

Laboratorium 5 – Selekcja zmiennych za pomocą przyrostu informacji

1 Cel ćwiczenia

Celem ćwiczenia jest analiza jednej z podstawowych metod selekcji zmiennych dyskretnych opartej na przyroście informacji. W zadaniu wykorzystywane będą pakiety **numpy** i **scipy.sparse**. Do wczytywania danych, można posłużyć się pakietami **pandas** (metoda **read_csv**) oraz **sklearn**.

2 Zadania

1. Używając standardowego słownika języka Python napisać funkcję `[xi, ni]=freq(x, prob=True)`, która dla zadanej kolumny danych x dyskretnych zwróci: unikalne wartości x_i , ich estymowane prawdopodobieństwa p_i lub częstości n_i .
2. Napisać funkcję `[xi, yi, ni] = freq2(x,y, prob=True)`, która dla zadanych kolumn danych x i y zwróci: unikalne pary wartości atrybutów x_i, y_i oraz łączny rozkład częstości lub licznosci n_i (w zależności od parametru **prob**).
3. Wykorzystując powyższe funkcje, napisać funkcje, które wyliczą: entropię `h=entropy(x)` oraz przyrost informacji `i=infogain(x,y)` zgodnie ze wzorami:

$$H(X) = - \sum_{i=1}^n \Pr\{X = x_i\} \log_2(\Pr\{X = x_i\})$$

Informacja wzajemna i przyrost informacji:

$$I(X, Y) = H(X) + H(Y) - H(XY)$$

$$I(Y, X) = H(Y) - H(Y|X)$$

gdzie:

$$H(Y|X) = \sum_{i=1}^k \Pr\{X = x_i\} H(Y|X = x_i)$$

4. Wczytać dane testowe `zoo.csv` oraz dokonać selekcji/stopniowania atrybutów z wykorzystaniem kryterium przyrostu informacji. Poszukać tych informacji, które wnoszą najwięcej informacji między sobą oraz, które z nich są bardziej pomocne przy rozpoznawaniu zwierząt (`animal` 1 kolumna).
5. Sprawdzić czy funkcje `freq`, `freq2` działają dla atrybutów rzadkich (pakiet `scipy.sparse`). Przerobić funkcje tak, aby działały dla atrybutów rzadkich.